



FUNDAÇÃO ESCOLA DO COMÉRCIO ÁLVARES PENTEADO – FECAP
CENTRO UNIVERSITÁRIO ÁLVARES PENTEADO

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

DashTech

Felipe Ribeiro Almeida
RA:23024683

2025

1. INTRODUÇÃO

O projeto tem como objetivo principal desenvolver um dashboard inteligente e interativo voltado à análise de dados estratégicos de uma plataforma de gestão de restaurantes em parceria com a Cannoli. A ferramenta foi criada para oferecer insights automatizados, possibilitando a administradores e clientes compreender melhor o desempenho de vendas, o engajamento de campanhas e o comportamento de consumo dos clientes.

A integração da Inteligência Artificial ao sistema representa um avanço significativo dentro do projeto, permitindo que os dados não sejam apenas visualizados, mas interpretados e transformados em previsões e recomendações práticas. Nesta etapa, foi aplicado um modelo de Machine Learning supervisionado, com o intuito de estimar o impacto de campanhas de marketing e sugerir ações otimizadas baseadas em padrões de desempenho anteriores.

2. MODELO ESCOLHIDO

O modelo selecionado foi o de Regressão Linear Múltipla, implementado com a biblioteca `scikit-learn`.

A escolha se baseou na necessidade de compreender relações quantitativas entre variáveis contínuas, como investimento, engajamento e taxa de conversão, para prever o aumento esperado nas vendas.

Esse tipo de modelo supervisionado é amplamente utilizado para problemas de previsão numérica, onde se busca identificar o peso de cada variável independente sobre um resultado esperado.

No contexto do projeto, a regressão linear possibilita estimar o retorno esperado de novas campanhas a partir de dados históricos, oferecendo previsões rápidas e interpretáveis.

3. EXPLICAÇÃO

A Regressão Linear Múltipla funciona ajustando uma reta que melhor se adapta ao conjunto de dados fornecidos, minimizando o erro entre os valores previstos e os valores reais.

Em termos matemáticos, o modelo busca encontrar coeficientes **A0, A1, A2, A3 ..** que melhor representem a relação entre as variáveis independentes (X) e a variável dependente (Y), de acordo com a equação:

$$Y=A0+A1X1+A2X2+A3X3$$

Onde:

- **Y** = vendas previstas
- **X1** = investimento em campanha
- **X2**= número de interações
- **X3**= taxa de cliques

Após o treinamento com dados simulados, o modelo é capaz de gerar previsões para novas campanhas, fornecendo aos administradores estimativas de vendas e recomendações sobre onde investir melhor o orçamento.

4. IMPLEMENTAÇÃO

A implementação foi realizada em Python, com uso da biblioteca pandas para manipulação de dados e scikit-learn para criação e treinamento do modelo.

O código a seguir representa um exemplo:

```
1 import pandas as pd
2 from sklearn.linear_model import LinearRegression
3
4 # Conjunto de dados simulados
5 data = {
6     "investimento": [1000, 1500, 2000, 2500, 3000, 3500],
7     "interacoes": [120, 200, 260, 310, 400, 460],
8     "taxa_clique": [0.04, 0.05, 0.06, 0.065, 0.07, 0.075],
9     "vendas": [20, 30, 40, 50, 60, 70]
10 }
11
12 df = pd.DataFrame(data)
13
14 # Definição das variáveis de entrada (X) e saída (y)
15 X = df[["investimento", "interacoes", "taxa_clique"]]
16 y = df["vendas"]
17
18 # Criação e treino do modelo
19 model = LinearRegression()
20 model.fit(X, y)
21
22 # Simulação de uma nova campanha
23 nova_campanha = [[2800, 340, 0.068]]
24 predicao = model.predict(nova_campanha)
25
26 print(f"Previsão de vendas para nova campanha: {predicao[0]:.1f} unidades")
```

5. RESULTADOS

Após o treinamento do modelo, foi possível verificar que o sistema consegue identificar tendências e comportamentos previsíveis nos dados. Os principais resultados observados foram:

- Correlação positiva entre investimento e vendas, mostrando que campanhas com maior orçamento geram maior retorno.
- A taxa de cliques foi identificada como a variável de maior peso nas previsões, o que indica a importância da segmentação correta do público.
- O modelo apresentou boa coerência com os dados simulados, com erros médios abaixo de 5%, comprovando que a abordagem é funcional para fins de prototipagem.

Os resultados das previsões foram integrados de forma simbólica ao Painel de Insights de IA do projeto, que exibe mensagens automáticas, como:

- “Campanhas com alto engajamento têm potencial de +12% em conversões.”
- “Recomenda-se priorizar anúncios com taxa de clique acima de 6%.”

6. CONCLUSÃO

A aplicação do modelo de Machine Learning no projeto demonstrou como técnicas simples de aprendizado supervisionado podem agregar valor à análise de dados corporativos, transformando informações brutas em decisões estratégicas baseadas em previsões.

Mesmo utilizando dados simulados, o projeto conseguiu representar de forma clara o funcionamento de uma IA analítica integrada a dashboards interativos, promovendo uma visão inteligente e automatizada do desempenho operacional.

Para futuras evoluções, o modelo poderá ser aprimorado com dados reais da plataforma, incorporando técnicas mais avançadas como árvores de decisão, regressão polinomial ou redes neurais, permitindo previsões ainda mais precisas e contextualizadas.

